

Типы локальных экономик России по безналичным тратам: динамическая атрибутированная сеть муниципальных образований

Екатерина Алексанян

МГУ имени М. В. Ломоносова, факультет ВМК

Проект Pulsar. Конкурс СберИндекса 2026, трек «Кластеризация»

9 октября 2026

Аннотация

Вопрос. Какие типы локальных экономик видны в безналичных тратах жителей 2016 муниципальных образований (МО) за 2023–2024 гг., как эти территории связаны между собой и как группы меняются во времени?

Метод. (1) Семь признаков на МО-месяц: состав трат (CLR долей шести категорий) и уровень трат относительно страны. Признаков Росстата в модели нет, они оставлены для проверки. (2) Сеть близости из трёх слоёв с разными источниками информации (поведение: сходство профилей; со-движение: лаговые корреляции приростов; география: дорожные расстояния), слитых диффузией SNF; граф месяца t использует только данные $\leq t$. (3) Семь методов на одинаковых входах, от k-means до KEFRiN и temporal Leiden, и десять индексов качества, сверенных с библиотекой Pattern. Нулевые модели и парный бутстрэп показывают, какие различия между методами значимы. (4) Сквозные типы и подтверждённые переходы (новый тип держится ≥ 3 месяцев при бутстрэп-уверенности $\geq 0,7$), индекс Шоррокса, события жизненного цикла; онлайн-проверка: центры 2023 г. классифицируют 2024 г. без пересчёта. (5) Интерпретация: профили по Миркину [15], дерево правил в рублях и процентах, внешняя проверка зарплатами, структурой занятости и населением Росстата.

Результаты. Шесть устойчивых типов локальных экономик: **мегаполисы и столичные районы** (16 % МО; траты 186 % от медианы страны, самый устойчивый тип), **промышленные города и пригороды** (20 %), **малые города и райцентры** (22 %), **аграрные районы на трассах** (16 %; самый подвижный), **сельская периферия** (21 %; траты 82 % медианы) и **Север и ресурсные территории** (6 %; дорогая логистика, вдвое меньшая доля маркетплейсов). Типы объясняют 61 % разброса зарплат и 48 % разброса населения по данным Росстата, не участвовавшим в обучении модели. За два года 68 % МО не сменили тип ни разу; индекс Шоррокса по подтверждённым переходам 0,02 в месяц и 0,17 за год (декабрь 2023 → декабрь 2024); ни один тип не возник и не исчез. Главный сдвиг периода: доля маркетплейсов удвоилась во всех типах, Север отстаёт. Шоки (паводок в Орске) видны как сдвиг структуры трат и падение уверенности типа, но тип не меняется. Апрельский разрыв 2023 г. вызван сменой методики, и правило подтверждения его отфильтровывает.

Воспроизводимость. Все числа воспроизводятся командой `make all` (время прогона в приложении B). Данные: Лаборатория СберИндекс, CC BY-SA 4.0. Репозиторий: <https://github.com/estnafinema0/sberindex-pulsar>; лендинг: <https://estnafinema0.github.io/sberindex-pulsar/>.

Содержание

Схема работы

1	Данные и признаки	3
1.1	Данные	3
1.2	Признаки месяца	3
2	Сеть: правило ребра и его влияние	4
2.1	Три слоя и формулы	4
2.2	Что меняет правило ребра	5
3	Методы и их сравнение	6
3.1	Семь вариантов на одних входах	6
3.2	Панель ICVI и её подводные камни	7
3.3	Результаты	7
4	Типы локальных экономик	11
4.1	Паспорта типов	11
4.2	Внешняя проверка на данных, не входивших в кластеризацию	13
5	Динамика	14
5.1	Сквозные типы и подтверждённые переходы	14
5.2	Out-of-time: 2023 → 2024	15
5.3	Кейсы	15
6	Выводы, ограничения, дальнейшая работа	16
A	Абляция правил ребра	18
B	Свойства ICVI (доказательства)	18
B	Конфигурации и время прогона	19

Схема работы

Конвейер показан на рис. 1; критерии и расположение кода в репозитории представлены в табл. 1.




Рис. 1. Схема работы

Таблица 1

Критерий	Раздел	Код	Тест
Методология	1–2	src/pulsar/features.py, graphs.py	tests/test_features.py, test_graphs.py
Сеть и атрибуты	2, прил. А	graphs.py, build_graphs.py	test_graphs.py
Сравнение методов	3	methods.py, run_cluster.py, compare.py	test_methods.py, test_evaluate.py
ICVI	3, прил. Б	icvi.py, evaluate.py	test_icvi.py (сверка с Pattern)
Интерпретация, воспроизводимость	4–5, README	dynamics.py, interpret.py	test_interpret.py
Визуализация	лендинг	site/	–

1 Данные и признаки

1.1 Данные

Основные данные – оценки средних безналичных трат жителя МО в месяц (руб.) по шести категориям («Все категории», Продовольствие, Здоровье, Маркетплейсы, Общественное питание, Транспорт), 303 126 строк, 2 190 МО, 24 месяца (01.2023–12.2024). МО попадает в месяц, только если оценка прошла порог качества, поэтому панель несбалансирована. Полная история есть у 2 016 МО, они образуют обучающую панель; остальные 174 МО классифицируются по ближайшему центру типа и показаны на карте с пометкой. В данных нет восьми приграничных регионов (Белгородская, Брянская, Воронежская, Курская, Ростовская области, Краснодарский край, Крым, Севастополь); 247 МО относятся к внутригородским территориям Москвы и Петербурга.

Дополнительно использованы расстояния между центрами МО по автодорогам (5,9 млн пар; у 148 пар «город / одноимённый район» расстояние нулевое из-за общего центра, замечанием на 5 км), индекс доступности рынков, справочник «Границы и изменения МО» (типы, статусы, регионы, полигоны) и, только для внешней проверки, Росстат (БДМО): зарплаты и численность работников по разделам ОКВЭД2, население (см. docs/external_data.md).

В данных есть два системных эффекта: (1) в апреле 2023 г. у 30–38 % МО синхронно падают оценки по «Здоровью» (–17 % медианно) и «Общепиту» (–18 %). (2) Сезонность сильная (декабрь +19 % к ноябрю, январь –23 %). Оба эффекта снимаются центрированием внутри месяца (п. 1.2) и правилом подтверждения перехода (п. 5.1).

1.2 Признаки месяца

Для МО i в месяце t берём доли шести компонент итога s_{ic} (пять категорий и «Прочее» $= 1 - \sum_c s_{ic}$; «Прочее» в медиане составляет 28 % итога, без него композиция неполна и CLR некорректен) и сам итог y_{it} .

- CLR долей [29]:

$$\text{clr}_{ic} = \ln s_{ic} - \frac{1}{6} \sum_{c'} \ln s_{ic'}. \quad (1)$$

Доли образуют композиционные данные, и евклидово расстояние между ними бессмысленно; CLR переводит их в пространство, где k-means, Ward и ядра корректны. Шесть компонент, сумма CLR равна нулю (ранг 5).

- Относительный уровень:

$$\ell_{it} = \ln(y_{it}/\text{med}_j y_{jt}). \quad (2)$$

Один признак «богатства» территории; деление на медиану страны в том же месяце убирает общий сезон и инфляцию, остаётся положение МО относительно страны.

- Причинное сглаживание: среднее за $t - 2..t$. Используется для уменьшения шума оценок и не использует данные о будущем (признаки месяца t известны в месяце t).
- Стандартизация внутри месяца: z -оценка по МО. Признаки сопоставимы между месяцами, сезон не влияет на расстояния; все семь признаков входят с равным весом.

Итог: $X_t \in \mathbb{R}^{2016 \times 7}$ для каждого из 24 месяцев. Признаки Росстата в X_t не входят, так как используются для внешней проверки.

2 Сеть: правило ребра и его влияние

2.1 Три слоя и формулы

Жюри предлагает три семейства близости: по схожести векторов трат, по взаимному опережению (лаговые корреляции, DTW) и по расстояниям между регионами. Мы строим по слою на каждое семейство так, чтобы слои несли разную информацию, и затем сливаем их. Граф месяца t использует только данные $\leq t$.

Слой 1, поведение (сходство профилей). $d_{ij} = \|x_i - x_j\|$ в пространстве признаков месяца; локальный масштаб σ_i равен расстоянию до 7-го соседа [25]; вес

$$w_{ij} = \exp(-d_{ij}^2 / (\sigma_i \sigma_j)); \quad (3)$$

ребро остаётся, если $i \in \text{kNN}_{10}(j)$ и $j \in \text{kNN}_{10}(i)$ (взаимный kNN режет «хабы» плотных зон); добавляются рёбра минимального остовного дерева, поэтому граф связный, без изолятов. Самонастраивающееся ядро нужно потому, что плотность МО в признаковом пространстве различается на порядок (сёла и столичные районы): один глобальный σ либо склеивает первых, либо рвёт вторых.

Слой 2, со-движение (лаговые корреляции). Z : стандартизованные лог-приросты итоговых трат за прошлые $W = 12$ месяцев за вычетом медианы страны (общий тренд убран). При $N = 2016 \gg W$ выборочная корреляция вырождена, поэтому используется оценка с усадкой [26]

$$\Sigma_{LW} = (1 - \delta)S + \delta\mu I, \quad \rho_{ij} = \Sigma_{ij} / \sqrt{\Sigma_{ii}\Sigma_{jj}}; \quad (4)$$

для лага $L = 1$ считается кросс-корреляция сдвинутых рядов, берём $\max_L \rho_{ij}^{(L)}$, отрицательные обнуляем, оставляем 10 сильнейших взаимно. В первые три месяца окна нет, слой пустой и в слиянии пропускается. DTW в работе не используется: на рядах длиной 12–24 точки выравнивание по времени мало отличается от сдвига на ± 1 месяц, который уже учитывает лаговая корреляция. A).

Слой 3, география (расстояния). $w_{ij} = \exp(-D_{ij}/200 \text{ км})$ по автодорогам (ж/д – в качестве запасного варианта, большой круг $\times 1,3$ для 1,2 % пар без дорог), 10 ближайших, симметризация по $\max$. 200 км примерно соответствуют радиусу «регионального рынка». Этот слой не зависит от трат и проверяет, добавляет ли пространство что-то к поведению.

Слияние через SNF [27]. Для каждого слоя строятся полная нормированная матрица $P^{(v)}$ и локальное ядро $S^{(v)}$ по 10 соседям; итерации

$$P^{(v)} \leftarrow S^{(v)} \overline{P^{(-v)}} S^{(v)\top}, \quad t = 10; \quad (5)$$

итога: среднее $P^{(v)}$, взаимный kNN_{10} и максимальное остовное дерево. SNF выбран вместо среднего весов, потому что диффузия усиливает рёбра, поддержанные несколькими слоями, и подавляет шум одного слоя. Вариант со средним весов реализован в коде (`fusion.method: mean`), но в этой работе не сравнивался.

Все гиперпараметры лежат в `configs/graph.yaml`.

2.2 Что меняет правило ребра

Таблица 2. Структура сети по слоям (медианы по 24 месяцам).

Слой	ср. степень	компонент	изолятов	ассорта- тивность	кластер. коэф.	алгебр. связность	неглад- кость, $x^T L x / x^T x$	ср. длина ребра в признаках
поведение	6.3	1	0.0 %	0.42	0.32	0.002	0.10	0.68
со-движение	5.8	20	0.8 %	0.35	0.19	0.004	0.61	2.51
география	12.5	1	0.0 %	0.16	0.59	0.000	0.43	2.09
слитый (SNF)	8.5	1	0.0 %	0.10	0.19	0.025	0.27	1.58

Слои почти не пересекаются по рёбрам (Жаккар множеств рёбер между любыми двумя слоями 0,015–0,035 в 2024-06), то есть несут разную информацию (табл. 2, рис. 2). Географический слой самый «кластеризованный» (коэффициент 0,59: соседи соседей тоже соседи) и самый гладкий по степеням. Поведенческий слой самый ассортативный, и рёбра у него самые короткие в признаковом пространстве ($0,68\sigma$ против 2,1 у географии), что ожидаемо: он построен из тех же признаков. Слой со-движения появляется с четвёртого месяца (нужно окно ≥ 3) и имеет изоляты: у части МО приросты ни с кем значимо не коррелируют. Слитый граф связный, без изолятов, со средней степенью 8,5 и промежуточной гладкостью признаков (0,27). Он сохраняет компактность поведения и добавляет рёбра географии и со-движения.




Рис. 2. Характеристики слоёв сети по месяцам: средняя степень, ассортативность, кластерный коэффициент, негладкость признаков на графе.

Таблица 3. ICVI при $K = 6$ для одного метода на разных слоях (медианы по месяцам).

Слой	Метод	SW	AVI	AVU	MQ= Q	ANUI
поведение	KEFRiN (сбал.)	0.217	0.887	0.524	0.701	0.606
	Leiden	0.159	0.948	0.433	0.711	0.670
	Spectral	0.164	0.936	0.526	0.632	0.628
со-движение	KEFRiN (сбал.)	0.216	0.414	0.505	0.221	0.342
	Leiden	-0.057	0.906	0.460	0.598	0.625
	Spectral	-0.046	0.959	0.367	0.320	0.700
география	KEFRiN (сбал.)	0.214	0.528	0.461	0.323	0.424
	Leiden	-0.042	0.993	0.363	0.714	0.729
	Spectral	-0.006	0.960	0.415	0.667	0.686
слитый (SNF)	KEFRiN (сбал.)	0.218	0.684	0.504	0.495	0.509
	Leiden	0.086	0.849	0.444	0.568	0.617
	Spectral	0.060	0.839	0.446	0.445	0.610

Таблица 4. Зависимость типологии от слоя: ARI между разбиениями одного метода на разных слоях (медиана по месяцам).

Метод	поведение ~ со-движение	поведение ~ география	со-движение ~ география	слой ~ слитый (медиана трёх)
KEFRiN (сбал.)	0.93	0.87	0.88	0.90
Leiden	0.12	0.15	0.09	0.23
Spectral	0.19	0.14	0.04	0.33

Выводы по табл. 3 и 4. (1) Для чисто сетевых методов правило ребра определяет модель целиком. Leiden на географии даёт AVI 0,99 и Q 0,71, но $SW < 0$: он выделяет региональные блоки, которые с типами экономики не совпадают. На со-движении SW тоже отрицательный. Типологии этих методов на разных слоях почти не связаны (ARI 0,1–0,3). (2) У KEFRiN с уравновешенными вкладами слой меняет сетевые индексы вдвое (Q от 0,22 на со-движении до 0,70 на поведении), но типология устойчива (ARI 0,87–0,93): структура трат задаёт типы, сеть уточняет границы между ними. (3) Слитый граф выбран основным, хотя на поведенческом слое Q выше: только слитый граф содержит информацию всех трёх семейств близости из критерия жюри, связан и даёт устойчивую типологию. Q при этом равен 0,50 против 0,70 у «автокоррелированного» поведенческого слоя, построенного из тех же признаков, что и атрибуты.

3 Методы и их сравнение

3.1 Семь вариантов на одних входах

Все методы получают одинаковые X_t и A_t (слитый граф), одинаковые K и seed. Порядок в табл. 5: от «только признаки» к «только сеть» и «оба». Критерий Leiden [24] и KEFRiN [4]:

$$\max_g Q_\gamma = \frac{1}{2m} \sum_{ij} \left(A_{ij} - \gamma \frac{k_i k_j}{2m} \right) \delta(g_i, g_j), \quad (6)$$

$$F = \rho \|Y - SC\|^2 + \xi \|P - SA\|^2, \quad P = A - \frac{kk^\top}{2m}. \quad (7)$$

Таблица 5. Методы сравнения.

Метод	Критерий	Входы	Комментарий
k-means	$\min \sum_k \sum_{i \in S_k} \ x_i - c_k\ ^2$	X_t	базовая линия по признакам
Ward	то же, агломеративно	X_t	детерминированная база, иерархия
Spectral	K собственных векторов нормированного лапласиана A_t , затем k-means	A_t	«чистая» сеть, релаксация нормированного разреза
Leiden	$\max Q_\gamma$ (6), γ подбирается под K	A_t	эталон сетевых методов [24]
temporal Leiden	мультислойная модулярность [20]: $+\omega \delta_{ij}$ между соседними месяцами, $\omega = 0,25$	$A_1..A_{24}$	единственный метод, где типы сквозные по построению
KEFRiN	F (7) [4], $\rho = \xi = 1$	X_t, A_t	метод жюри, реализован по формулам
KEFRiN (сбаланс.)	то же, $\xi \leftarrow \xi \ Y\ ^2 / \ P\ ^2$	X_t, A_t	при $\rho = \xi = 1$ на разреженной сети $\ P\ ^2 \approx 2\%$ от $\ Y\ ^2$ и сеть почти не влияет; балансировка уравнивает вклады

KEFRiN: чередование «объект $\rightarrow$ ближайший центр по сумме двух расстояний» и «центры = средние», инициализация K-Means++, 5 стартов, лучший по F ; каждый шаг не увеличивает F (тест). Temporal Leiden: разрешение γ подбирается бисекцией так, чтобы медианное по срезам число сообществ размером ≥ 5 равнялось K ; мелкие сообщества присоединяются к соседям. Для помесечных методов сквозные номера получаются венгерским сопоставлением по Жаккару между соседними месяцами (`src/pulsar/align.py`).

3.2 Панель ICVI и её подводные камни

Считаем шесть индексов из Положения (SW [7], CH [8], S_Dbw [10] по признакам; AVI, AVU, MQ по сети) и дополняем их ANUI, DBI [9], CH/ N и плотностной модулярностью, следуя панели из работ жюри [2, 1]. Все реализации свои (`src/pulsar/icvi.py`). Сетевые индексы численно совпадают с библиотекой Pattern Лаборатории СберИндекс до 10^{-9} (тест `test_matches_pattern_library`), S_Dbw совпадает с пакетом `s-dbw` в его соглашениях и отдельно сверен со статьёй [10].

Обозначения: S_{ab} – суммарный вес рёбер между кластерами a и b (внутренний считается дважды), $\text{out}_a = \sum_{b \neq a} S_{ab}$.

$$\text{AVI} = \frac{1}{K} \sum_a \frac{S_{aa}}{S_{aa} + \text{out}_a}, \quad (8)$$

$$\text{AVU} = \frac{1}{K} \sum_a \sum_{b \neq a} \frac{S_{ab}}{\text{out}_a + \text{out}_b - S_{ab}}, \quad (9)$$

$$\text{ANUI} = 1/(\text{AVU} + 1/\text{AVI}). \quad (10)$$

- AVI (8): средняя изолируемость [5], больше лучше. У случайного разбиения $\approx 1/K$ (тест).
- AVU (9): средняя объединяемость, меньше лучше. Вырожден при малых K : при $K = 2$ тождественно равен 1, при $K = 3$ равен $2/3$ для любого разбиения с непустым разрезом (доказательство в прил. Б, проверено тестом); у случайного разбиения $\approx (K-1)/(2K-3)$ (0,60 при $K = 4$, 0,55 при $K = 7$). AVU инвариантен к масштабу внутренних весов и видит только форму разреза. Поэтому сетка K начинается с 4, а AVU сравнивается через z -оценки.
- ANUI (10): сводный индекс Pattern [5, 6]; набор индексов для атрибутированных сетей следует [3].
- MQ. В работах жюри MQ означает модулярность Ньюмана–Гирвана Q [11], её и считаем как MQ. Для полноты в приложении даны MQ Манкоридиса [12] и TurboMQ [13]; на неориентированном графе $\text{TurboMQ} \equiv K \cdot \text{AVI}$ (прил. Б), то есть новой информации он не несёт.
- SW, CH, DBI считаются через `sklearn`; CH растёт $\sim N$, поэтому рядом даём CH/ N . У S_Dbw меньше лучше.

Два вида нулевых моделей: (1) перестановка меток при сохранении размеров кластеров даёт z -оценку и p каждого индекса (сколько структуры в разбиении по сравнению со случайным разбиением тех же размеров); (2) configuration model переставляет рёбра с сохранением степеней при фиксированных метках (сколько в сетевых индексах объясняется одними степенями). Значимость различий между методами оцениваем парным бутстрэпом по 24 месяцам: ДИ разности средних индексов и доля бутстрэп-выборок, где метод лучший.

3.3 Результаты

Случайные уровни при $K = 6$: $\text{AVI} \approx 0,167$, $\text{AVU} \approx 0,556$. Картина устойчива по месяцам ($\text{IQR SW} \leq 0,02$) и по K (рис. 3):

Таблица 6. Индексы при $K = 6$: медиана по 24 месяцам (для SW $\pm$ межквартильный размах). Temporal Leiden считался на сетке $K \in \{4, 6, 8\}$.

Метод	SW $\uparrow$	CH $\uparrow$	S_Dbw $\downarrow$	AVI $\uparrow$	AVU $\downarrow$	MQ = Q $\uparrow$	ANUI $\uparrow$
k-means	0.218 ± 0.005	646	0.87	0.665	0.517	0.481	0.495
Ward	0.160 ± 0.026	518	0.84	0.704	0.486	0.508	0.525
Spectral	0.060 ± 0.054	214	0.81	0.839	0.446	0.445	0.610
Leiden	0.086 ± 0.049	293	0.73	0.849	0.444	0.568	0.617
KEFRiN ($\rho = \xi = 1$)	0.218 ± 0.006	646	0.84	0.665	0.516	0.483	0.496
KEFRiN (сбаланс.)	0.218 ± 0.006	645	0.88	0.684	0.504	0.495	0.509
temporal Leiden ($\omega = 0,25$)	0.108	290	0.73	0.830	0.406	0.536	0.622

- Методы по признакам (k-means, Ward, KEFRiN) выигрывают по SW, CH, S_Dbw; методы по сети (Leiden, Spectral) выигрывают по AVI, AVU, MQ и ANUI (табл. 6). Расхождение образует фронт Парето «признаки / сеть» (рис. 4) и от реализаций не зависит. Leiden при $K = 6$ даёт $Q = 0,57$, но $SW = 0,09$: его сообщества почти не различаются по составу трат и потому не читаются как типы экономики.
- AVU у методов по признакам идёт параллельно случайному уровню (пунктир на рис. 3). Индекс падает с ростом K из-за смены базового уровня, качество разбиения при этом не растёт. Поэтому AVU мы сравниваем только через z -оценки.
- KEFRiN в исходной параметризации ($\rho = \xi = 1$) почти совпадает с k-means (ARI 0,97 по медиане месяцев): при разреженной сети $\|P\|_F^2$ составляет 2% от $\|Y\|_F^2$, и сетевое слагаемое не влияет на решение. Сбалансированный вариант ($\xi_{\text{eff}} \approx 43$) сохраняет SW k-means и поднимает AVI, MQ и ANUI. Из всех методов только он сдвигает решение к сети без потери читаемости профилей.




Рис. 3. Индексы качества в зависимости от K ; пунктир – уровень случайного разбиения.

Рейтинги расходятся (табл. 7). Борда и частота лидерства награждают Leiden за три сетевых индекса и S_Dbw, пороговое правило наказывает его за провалы по SW и CH и выводит вперед Ward; temporal Leiden набирает частоту лидерства на сетевых индексах при $SW = 0,11$. Ни одно сводное правило не выделяет единственного победителя. Поэтому выбираем по заранее объявленным критериям: (1) Парето-эффективность, (2) отсутствие худших оценок по пороговому правилу, (3) статистически значимое преимущество над ближайшим простым методом, (4) бутстрэп-устойчивость, (5) пригодность для интерпретации (кластеры должны различаться по составу трат, иначе это не «типы экономики»).

Сбалансированный KEFRiN не уступает k-means ни по одному индексу признаков (разности SW и S_Dbw незначимы) и значимо выигрывает по всем четырём сетевым (табл. 8). Против Leiden проигрыш по сети значим, но выигрыш по признакам на порядок больше по z . Нулевая модель графа (configuration model, фиксированные метки): $z(Q) = 129$ для KEFRiN и 134 для Leiden, то есть обе типологии несут структуру сверх распределения степеней. $z(AVU)$




Рис. 4. Фронт Парето «признаки / сеть»: SW против модулярности Q при $K = 6$.

Таблица 7. Сводные рейтинги при $K = 6$. Борда по шести индексам Положения; пороговое правило Алескерова [16, 17]: оценки по терциям, лексикографически по числу худших оценок; частота лидерства: доля бутстрэп-выборок месяцев, где метод лучший, усреднённая по индексам.

Метод	Борда ↑	Пороговое правило: оценок «плохо / средне / хорошо»	Ранг по порогу	Частота лидерства (бутстрэп)
Leiden	25	2 / 0 / 4	2	0.04
temporal Leiden	24	2 / 1 / 3	3	0.91
Ward	19	0 / 6 / 0	1	0.00
KEFRiN (сбаланс.)	16	3 / 2 / 1	4	0.02
KEFRiN ($\rho = \xi = 1$)	15	4 / 1 / 1	7	0.02
k-means	14	4 / 0 / 2	6	0.00
Spectral	13	3 / 2 / 1	5	0.00

Таблица 8. Парный бутстрэп по 24 месяцам: разность средних и 95 % ДИ (ориентация «больше – лучше»). Жирным выделены ДИ, не содержащие нуля.

Индекс	KEFRiN (сбаланс.) – k-means	KEFRiN (сбаланс.) – Ward	KEFRiN (сбаланс.) – Leiden	Leiden – k-means
SW	+0.002 [−0.000; +0.006]	+0.058 [+0.050; +0.065]	+0.128 [+0.113; +0.144]	−0.126 [−0.139; −0.113]
CH	−3.245 [−5.598; −1.424]	+118.594 [+110.958; +125.813]	+342.695 [+326.943; +358.272]	−346 [−361; −331]
S_Dbw	−0.000 [−0.057; +0.044]	+0.008 [−0.100; +0.122]	−0.086 [−0.156; −0.017]	+0.085 [+0.012; +0.158]
AVI	+0.016 [+0.011; +0.022]	−0.016 [−0.023; −0.009]	−0.166 [−0.174; −0.157]	+0.182 [+0.171; +0.193]
AVU	+0.013 [+0.009; +0.018]	−0.015 [−0.024; −0.006]	−0.062 [−0.076; −0.047]	+0.075 [+0.061; +0.089]
MQ	+0.007 [+0.004; +0.009]	−0.018 [−0.024; −0.012]	−0.081 [−0.096; −0.065]	+0.087 [+0.072; +0.102]
ANUI	+0.012 [+0.008; +0.017]	−0.013 [−0.019; −0.007]	−0.109 [−0.119; −0.100]	+0.122 [+0.111; +0.132]

у Leiden и Spectral отрицательны (-8 , -20): их разрезы «лучше случайного» только за счёт формы разреза, навязанной степенями.

Итог по методам. Основной метод: KEFRiN (сбалансированный). Он Парето-эффективен; по пороговому правилу уступает лишь Ward, Leiden и temporal Leiden, у которых провалы по устойчивости или по SW; значимо лучше k-means по сети при равной компактности; устойчивость ARI 0,78 при $K = 6$ против 0,52 у Leiden. Из лидеров только он использует и признаки, и сеть, как требует постановка задачи. Устойчивость по бутстрэпу при $K = 6$ (ARI между подвыборками, [28]): k-means 0,81, Spectral 0,79, KEFRiN сбаланс. 0,78, Leiden 0,52, Ward 0,39. Ward, лидер порогового правила, отпадает: агломеративная иерархия перестраивается при удалении 20 % МО. Эффект сети мал: итоговая типология совпадает с k-means на ARI 0,91, тип отличается лишь у 4 % МО. Сеть сдвигает границы типов, карта в целом сохраняется; эти 4 % МО повышают внешнюю объяснимость зарплат с η^2 0,47 (k-means) до 0,61 (п. 4.2). Leiden остаётся эталоном «чисто сетевого» взгляда и показан на карте как альтернативная линза.

Таблица 9. Сильные стороны и ограничения методов (по табл. 6 и бутстрэп-устойчивости при $K = 6$).

Метод	Сильные стороны	Ограничения	Когда применять
k-means	SW 0,218, CH 646; устойчивость ARI 0,81	сеть не использует; MQ 0,481	базовая линия по признакам
Ward	детерминирован, даёт иерархию; MQ 0,508	устойчивость ARI 0,39; SW 0,160	разведка структуры, не итоговая типология
Spectral	AVI 0,839, ANUI 0,610; устойчивость 0,79	SW 0,060: профили не читаются	когда нужен чисто сетевой разрез
Leiden	MQ 0,568, AVI 0,849	SW 0,086; устойчивость 0,52	эталон сетевых сообществ, альтернативная линза
temporal Leiden	сквозные метки по построению (ARI соседних месяцев 0,95); ANUI 0,622	несбалансирован: при $K = 4$ крупнейшее сообщество 71 % МО; SW 0,108	когда важна непрерывность меток, а не баланс типов
KEFRiN ($\rho = \xi = 1$)	учитывает и признаки, и сеть; SW 0,218	сеть почти не влияет: ARI с k-means 0,97	при сопоставимых масштабах признаков и сети
KEFRiN (сбаланс.)	SW 0,218 при MQ 0,495 и ANUI 0,509; устойчивость 0,78	сетевые индексы ниже, чем у Leiden	основной метод: признаки и сеть вместе

Таблица 10. Выбор K для KEFRiN (сбаланс.). Три критерия, объявленных заранее: z_{AVU} (единственный сетевой индекс с пиком по K), z_{SW} и бутстрэп-устойчивость (10 подвыборок по 80 % МО, медиана ARI между подвыборками).

K	z_{SW}	z_{AVU}	z_{MQ}	SW	устойчивость ARI (бутстрэп)	Жаккар худшего кластера
4	40.4	6.5	97	0.241	0.89	0.76
5	30.5	9.1	106	0.240	0.86	0.86
6	26.2	16.5	114	0.218	0.78	0.78
7	20.7	2.7	116	0.208	0.67	0.46
8	24.9	4.4	124	0.202	0.61	0.51
9	14.9	0.2	132	0.200	0.53	0.46
10	13.5	-5.9	140	0.192	0.56	0.37

Двухшаговое правило (табл. 10). *Шаг 1:* сумма нормированных критериев выбирает $K = 4$ (укрупнённые группы: города и столичные районы; малые города и сельская периферия; часть северных территорий; смешанная группа районов на трассах). Ближайший кандидат

$K = 6$ имеет максимальный z_{AVU} , вложен в $K = 4$ на 82 % (доля МО, чей подтип целиком лежит в одном макротипе) и добавляет два содержательных и устойчивых типа: мегаполисы отделяются от крупных городов, Север отделяется от промышленных городов. *Шаг 2:* среди $K > 4$ выбирается ближайший уровень, где z_{AVU} максимален, а худший по Жаккару кластер устойчив ($\geq 0,75$); это $K = 6$. Основной уровень типологии составляют 6 подтипов, макроуровень $K = 4$ служит агрегацией; оба уровня воспроизводятся из одних файлов (`outputs/compare/k_selection.csv`). Ограничение: метод, K и балансировка выбирались по всем 24 месяцам, включая 2024 г.; без будущего строятся только признаки, граф и онлайн-разметка п. 5.2.

Temporal Leiden ($\omega = 0,25$, сетка $K \in \{4, 6, 8\}$) даёт сквозные метки по построению (ARI соседних месяцев 0,95), но разбиение сильно несбалансировано (при $K = 4$ крупнейшее сообщество охватывает 71 % МО), $SW = 0,16$, $Q = 0,46$. При $\omega = 0,5$ бисекция по γ давала вырожденное решение (одно сообщество на 90 % узлов). Как единая модель динамики он проигрывает связке «помесичный KEFRiN + подтверждённые переходы» и по качеству, и по читаемости; подробности в прил. А.

4 Типы локальных экономик

4.1 Паспорта типов

Тип МО определяется как модальный подтверждённый тип за 2024 г. (у 84,9 % МО он совпадает с типом в опорном месяце 2023-12). Профили по Миркину [14] объясняют $B/T = 62,8$ % дисперсии признаков. Дерево решений глубины 3 на исходных единицах (доли в %, траты в рублях) воспроизводит типы с точностью 77 % (кросс-валидация 74 %), то есть каждый тип описывается тремя-четырьмя порогами, понятными без модели (рис. 6).

Таблица 11. Паспорта типов: медианы по МО типа (2024 г.). Доли – в % от итога трат; зарплата и население взяты из Росстата и в кластеризации не участвовали.

Тип	МО	Траты на жителя, руб. (% к мед.)	Продоволь- ствие	Марке- тплей- сы	Обще- пит	Транс- порт	Прочее	Зарпла- та, руб.	Насе- ление, тыс.
Сельская периферия	424 (21 %)	21 868 (82 %)	47.8	19.2	1.2	5.1	21.3	40 183	13
Промышленные города и пригороды	399 (20 %)	32 336 (121 %)	40.4	15.2	4.4	6.2	29.0	58 310	61
Малые города и райцентры	440 (22 %)	24 614 (92 %)	45.8	17.2	2.0	4.2	25.7	47 426	20
Аграрные районы на трассах	319 (16 %)	23 795 (89 %)	46.1	15.1	2.0	6.0	26.0	46 035	19
Мегаполисы и столичные районы	318 (16 %)	49 560 (186 %)	32.4	13.0	7.6	7.2	33.9	108 118	84
Север и ресурсные территории	116 (6 %)	41 098 (154 %)	42.7	10.1	3.7	4.7	33.3	104 926	18

Типичные МО

Сельская периферия: Хотынецкий, Мучкапский, Барышский

Промышленные города и пригороды: Беловский, Сызрань, Сысертский

Малые города и райцентры: Козьмодемьянск, Дегтярск, Еткульский

Аграрные районы на трассах: Чистозерный, Тогучинский, Карагайский

Мегаполисы и столичные районы: Чертаново Центральное, Орехово-Борисово Северное, Ясенево

Север и ресурсные территории: Охинский, Зейский, Заполярный

Сельская периферия. Самый низкий уровень трат (82 % медианы страны). Почти половина уходит на продовольствие, общепита практически нет, аптеки и маркетплейсы заметны

как замена офлайн-торговли. Муниципальные районы Черноземья, Поволжья и юга Сибири с сельским населением, низкими зарплатами (около 40 тыс. руб.) и занятостью в образовании и сельском хозяйстве.

Промышленные города и пригороды. Траты выше среднего (121 % медианы), доля продовольствия ниже, общепит заметен. Города и городские округа с преобладанием городского населения, зарплатой около 58 тыс. руб. и обрабатывающей промышленностью как главной отраслью: индустриальный Урал, Кузбасс, Подмосковье, Поволжье.

Малые города и райцентры. Уровень трат чуть ниже среднего (92 %), структура смешанная: продовольствие и маркетплейсы выше среднего, транспорт ниже. Малые города и районы с райцентром в Центре, Поволжье и на Урале, зарплата около 47 тыс. руб. Самый «переходный» тип: граничит и с селом, и с промышленными городами.

Аграрные районы на трассах. Низкий уровень трат (89 %) при повышенной доле транспорта (топливо, переезды). Чисто сельские районы вдоль магистралей и в республиках Поволжья, Алтая и Забайкалья, с худшей доступностью рынков среди «материковых» типов. Самый подвижный тип: чаще других меняет принадлежность.

Мегаполисы и столичные районы. Траты почти вдвое выше медианы страны (186 %), на продовольствие приходится лишь треть, доли общепита и транспорта максимальные. Внутригородские территории Москвы и Петербурга (233 из 318 МО типа) и крупнейшие региональные центры; зарплата свыше 100 тыс. руб., максимальная доступность рынков. Самый устойчивый тип.

Север и ресурсные территории. Высокий уровень трат (154 %) при большой доле «прочих» категорий и вдвое меньшей доле маркетплейсов: логистика дорогая, онлайн-канал слабый. Якутия, ЯНАО, Сахалин, север Красноярского края и Коми; зарплата свыше 100 тыс. руб., доля добывающих отраслей втрое выше медианы, доступность рынков минимальная.

Рис. 5 показывает профили в σ ; полные паспорта с типичными и пограничными МО есть на лендинге и в `outputs/interpret/types_summary.json`.




Рис. 5. Профили типов в единицах стандартного отклонения признаков.

Доля «Общественное питание» $\leq 3,3\%$
 Доля «Транспорт» $\leq 4,8\%$
 Доля «Прочее» $\leq 21,8\% \Rightarrow$ **Село**
 Доля «Прочее» $> 21,8\% \Rightarrow$ **Малые города**
 Доля «Транспорт» $> 4,8\%$
 Доля «Прочее» $\leq 23,3\% \Rightarrow$ **Село**
 Доля «Прочее» $> 23,3\% \Rightarrow$ **Районы на трассах**
 Доля «Общественное питание» $> 3,3\%$
 Доля «Общественное питание» $\leq 5,9\%$
 Доля «Прочее» $\leq 32,6\% \Rightarrow$ **Промгорода**
 Доля «Прочее» $> 32,6\% \Rightarrow$ **Север и ресурсы**
 Доля «Общественное питание» $> 5,9\%$
 Итог на жителя $\leq 36\,654,1$ руб. $\Rightarrow$ **Промгорода**
 Итог на жителя $> 36\,654,1$ руб. $\Rightarrow$ **Мегаполисы**

Рис. 6. Правила дерева решений глубины 3 (сокращённо; полностью в `rule_tree.txt`, каталог `outputs/interpret`).

4.2 Внешняя проверка на данных, не входивших в кластеризацию

Таблица 12. Связь типов с внешними переменными. η_H^2 – доля дисперсии, объяснённая типом, по Краскелу–Уоллису; V Крамера для категориальных; все переменные вне признаков кластеризации.

Внешняя переменная	Статистика	Сила связи	p
Регион (справочник)	V Крамера	0.63	$< 0,001$
Средняя зарплата (Росстат)	η_H^2	0.61	$< 0,001$
Тип МО (район / округ / внутригородская территория)	V Крамера	0.54	$< 0,001$
Число работников организаций	η_H^2	0.50	$< 0,001$
Население	η_H^2	0.48	$< 0,001$
Доля городского населения	η_H^2	0.47	$< 0,001$
Индекс доступности рынков (СберИндекс)	η_H^2	0.35	$< 0,001$
Ведущая отрасль занятости	V Крамера	0.35	$< 0,001$
Доля бюджетного сектора в занятости	η_H^2	0.23	$< 0,001$
Статус (центр субъекта / ЗАТО)	V Крамера	0.22	$< 0,001$
Работников на жителя	η_H^2	0.16	$< 0,001$
Доля добычи и энергетики в занятости	η_H^2	0.16	$< 0,001$
Концентрация занятости (ННІ)	η_H^2	0.03	$< 0,001$

Базовые линии. Чтобы $\eta^2 = 0,61$ по зарплате что-то значило, его нужно сравнить с простыми альтернативами. Шесть групп МО только по уровню трат объясняют зарплату лучше (η^2 0,72), регион даёт 0,70, k-means на тех же признаках 0,47, административный тип МО 0,36; без внутригородских территорий Москвы и Петербурга типы дают 0,48, уровень трат 0,62. Значит, по зарплате типология уступает одномерной шкале «богатства»: типы различают ещё и структуру трат (село с маркетплейсами против села с продовольствием при одинаковом уровне). При этом по зарплате она информативнее k-means на тех же признаках (0,61 против 0,47) за счёт сети и балансировки. Поэтому ниже акцент сделан на переменных структуры экономики (отрасли, урбанизация, доступность рынков).

Что сходится (табл. 12): типы объясняют 61 % разброса зарплат и 48 % разброса населения, хотя ни того ни другого модель не видела; административный тип МО связан с типологией с $V = 0,54$; доступность рынков минимальна у Севера и максимальна у мегаполисов; у Севера доля добывающих отраслей втрое выше медианы. Что не сходится и почему. Регион объясняет типологию сильнее всего ($V = 0,63$): отчасти это география экономики, отчасти

региональные особенности безналичного охвата. Ведущая отрасль занятости по Росстату (без малого бизнеса) связана с типами слабее зарплате ($V = 0,35$): у малых МО это почти всегда «образование», а торговля и услуги, формирующие траты, в выборке Росстата недопредставлены.

5 Динамика

5.1 Сквозные типы и подтверждённые переходы

Метки месяцев связываются венгерским сопоставлением по Жаккару; номера типов присваиваются по убыванию размера в опорном месяце 2023-12. Сырые помесечные метки подвержены частым сменам типа: 4112 смен типа за 23 перехода, без единой смены остаются лишь 36,7 % МО. Правило подтверждения (новый тип держится не менее 3 месяцев подряд, и средняя бутстрэп-вероятность назначенного типа за эти месяцы не ниже 0,7) оставляет 963 подтверждённые смены у 651 МО; 67,7 % МО не меняют тип ни разу. Разложение сырых смен: 67,9 % составляет шум (новый тип продержался меньше трёх месяцев или МО вернулось в прежний тип), 23,4 % подтверждены, остальное приходится на «кандидатов» в хвосте ряда (ещё не прошло три месяца). Сезонность видна и после фильтра: подтверждённые смены чаще начинаются в июне и январе (в 2,2 и 2,1 раза чаще равномерного), 4,4 % смен приходится на пару декабрь→январь, 3,9 % повторяются у того же МО ровно через 12 месяцев.

Индекс Шоррокса [23] матрицы переходов P :

$$M = \frac{K - \text{tr } P}{K - 1}. \quad (11)$$

По сырым меткам M равен 0,155 (lag 1) и 0,413 (lag 12), по подтверждённым 0,023 и 0,208. Здесь lag 1 и lag 12 – среднее по всем парам месяцев, отстоящих на 1 и 12 месяцев; одна годовая пара декабрь 2023 → декабрь 2024 даёт 0,169 (в аннотации округлено до 0,17). Диагональ годовой матрицы (рис. 7): мегаполисы 0,96, Север 0,90, промышленные города 0,88, село 0,85, малые города 0,82, аграрные районы на трассах 0,75. Последний тип самый подвижный, и его главный обмен идёт с малыми городами (50 МО туда, 32 обратно). События жизненного цикла [21, 22] по Greene [21] (порог Жаккара 0,3) на подтверждённых типах сводятся к *continue* (138 событий): за два года ни один тип не родился, не умер, не слился и не разделился. Меняются отдельные МО, сами типы сохраняются.




Рис. 7. Размеры подтверждённых типов по месяцам и матрица переходов через 12 месяцев.

Бутстрэп-уверенность (30 подвыборок по 80 % МО, выравнивание к опорному разбиению): медиана 0,97, у 90 % пар «МО × месяц» уверенность $\geq 0,7$; на карте она показана прозрачностью. Оговорки: подтверждение ретроспективно на два месяца (месяц, когда смена становится известна онлайн, хранится отдельно в *confirmed_month*); подвыборки по 80 % мало сдвигают центры, поэтому уверенность скорее завышена.

5.2 Out-of-time: 2023 → 2024

Проверка динамики идёт без данных будущего: центры типов считаются только по 12 месяцам 2023 г., каждый месяц 2024 г. классифицируется ближайшим центром без пересчёта. Согласие онлайн-разметки с полной (где 2024 г. участвовал в кластеризации): ARI 0,68, совпадение типа у 84,2 % МО. Согласие падает с 0,78 в январе до 0,65 в декабре, потому что центры типов дрейфуют, прежде всего из-за волны маркетплейсов (п. 5.3). Из 682 подтверждённых смен 2024 г. онлайн-режим воспроизводит 265 (полнота 0,39, точность 0,47; с точным месяцем 0,16): часть «смен» полной разметки отражает движение центров типов при неизменных МО. Годовой Шоррокс онлайн равен 0,238 против 0,169 в полной разметке.

5.3 Кейсы

Орск: паводок апреля 2024. 5 апреля 2024 г. прорыв дамбы в Орске затопил часть города. В данных СберИндекса уровень трат почти не изменился (отношение к медиане страны держится на 1,15–1,25 весь 2024 год), сдвинулась структура: доля продовольствия подскакивает с 37,9 % до 40,1 %, доля маркетплейсов падает с 14,0 % до 12,4 % (логистика), здоровья с 4,7 % до 4,2 %. Тип МО («промышленные города и пригороды») не меняется, но бутстрэп-уверенность в нём падает с 0,83–1,00 до 0,50–0,57 в июне–сентябре 2024 г. и восстанавливается к декабрю; на карте это видно как более бледная заливка МО в режиме «слой неопределённости».

Апрель 2023: методологический разрыв. В апреле 2023 г. у 30–38 % МО синхронно падают оценки по «Здоровью» (медианно –17 %) и «Общепиту» (–18 %) при почти неизменном итоге. Это признак смены методики оценки; с поведением жителей разрыв не связан. Помесячная кластеризация реагирует: 567 сырых смен типа в апреле против 90–230 в соседних месяцах. Правило подтверждения (новый тип ≥ 3 месяцев и бутстрэп-уверенность $\geq 0,7$) оставляет из них 62. Подсчёт смен типа по сырым меткам показал бы в этом месяце массовую перестройку, которой в экономике не было.

Объединения МО 2024 года: Павлово-Посадский и Сасовский округа. С марта 2024 г. Павловский Посад и Электрогорск объединены в Павлово-Посадский округ (`union_22`), Сасово и Сасовский район объединены в Сасовский округ (`union_23`). В данных предшественники живут по февраль 2024 г., преемники появляются с марта, поэтому ни те ни другие не входят в обучающую панель полной истории и классифицируются по ближайшему центру типа в каждом месяце. На них проверяется устойчивость типологии к новым объектам. Павлово-Посадский округ наследует тип обоих предшественников (промышленные города и пригороды, все 10 месяцев); Сасовский округ наследует тип города Сасово (малые города) в 8 из 10 месяцев, потому что город доминирует в тратах объединённой территории. Смена идентификатора МО ложной смены типа не создаёт.

Волна маркетплейсов: село догоняет, Север отстаёт. За два года медианная доля маркетплейсов в тратах удвоилась во всех типах: в сельской периферии с 11,4 % до 22,8 %, в промышленных городах с 9,3 % до 18,4 %, в мегаполисах с 8,5 % до 16,0 % (рис. 8). Онлайн-канал растёт быстрее всего там, где офлайн-торговли меньше, отсюда «догоняющее село». Север и ресурсные территории растут в размах не медленнее (5,1 % → 12,5 %), но их доля весь период остаётся вдвое ниже остальных: разрыв в онлайн-доступе сохраняется из-за логистики. Признаки центрируются внутри месяца, поэтому эта общестрановая волна не создаёт ложных смен типа (в отличие от решений, где доли берутся как есть). Она видна как сдвиг центров типов, из-за которого онлайн-классификация 2024 года по центрам 2023-го даёт ARI 0,68.

Каждый кейс воспроизводится из артефактов `outputs/` (источники перечислены в `docs/cases.json`) и показан на лендинге кнопкой «показать на карте».




Рис. 8. Медианная доля маркетплейсов в тратах по типам, 2023–2024 гг.

6 Выводы, ограничения, дальнейшая работа

Выводы

1. В безналичных тратах устойчиво читаются шесть типов локальных экономик, и они совпадают с экономической географией страны, проверенной независимыми данными.
2. Правило ребра меняет сеть сильнее, чем типологию: слои почти не пересекаются (Жаккар-рёбер 0,02–0,04), но при разумном весе признаков итоговые типы устойчивы к слою; сеть уточняет границы типов (прил. А).
3. Сравнение методов без доверительных интервалов вводит в заблуждение: разные сводные правила дают разных лидеров, и выбрать метод обоснованно можно только по явным критериям (Парето-эффективность, отсутствие провалов, значимость, устойчивость, читаемость).
4. Большая часть «динамики» месячной кластеризации оказывается шумом: из 4112 сырых смен подтверждаются 963, а онлайн-проверка показывает, что и среди них часть объясняется дрейфом центров.
5. Для практики карта с уверенностью полезнее самих меток: шок виден по падению уверенности при неизменном типе.

Кому и зачем

Региональным органам и аналитикам типология даёт четыре инструмента. (1) Перечень МО с подтверждённой сменой типа – сигнал для проверки. (2) Падение бутстрэп-уверенности ниже 0,7 – индикатор шока без смены типа: у Орска она опускалась до 0,50–0,57 в июне–сентябре 2024 г. при обычных 0,83–1,00. (3) Подбор сопоставимых МО по типу для сравнения политик. (4) Разрыв в онлайн-доступе Севера: доля маркетплейсов 12,5 % против 16–23 % у остальных типов в декабре 2024 г.

Ограничения

Панель включает только МО с оценками, прошедшими порог качества (нет 8 регионов и части малых МО); траты безналичные и только клиентов Сбера, что смещает уровень в пользу городов; апрельский разрыв 2023 г. вызван сменой методики; внутригородские территории Москвы и Петербурга не являются самостоятельными экономиками и образуют отдельный

тип из-за устройства данных; подтверждение перехода ретроспективно на 2 месяца (месяц, когда смена становится известна онлайн, хранится отдельно).

Дальнейшая работа

Трикластеризация [18, 19] куба $МО \times \text{категория} \times \text{месяц}$; совместная модель «типология + переходы» (скрытая марковская модель на центрах типов) вместо правила подтверждения; добавление категорий трат при расширении набора; проверка типов на данных индекса мобильности по всем регионам, когда они появятся.

Список литературы

- [1] Shalileh S., Antonov E., Tsyplakova D. Internal cluster validity indices for attributed networks: A controlled comparative study // *Expert Systems with Applications*. 2026. Vol. 333. Art. 133912. DOI: 10.1016/j.eswa.2026.133912.
- [2] Shalileh S., Antonov E. A., Tsyplakova D. A. Cluster Validity across Attribute and Network Spaces: Empirical Benchmarks for Attributed Networks Clustering // *Doklady Mathematics*. 2025. Vol. 112, No. 3. P. 553–564. DOI: 10.1134/S1064562425700589.
- [3] Shalileh S., Antonov E., Tsyplakova D. Profiling Consumption Using Attributed Network Clustering // *Complex Networks & Their Applications XIV. Studies in Computational Intelligence*. Cham: Springer, 2026. P. 77–88. DOI: 10.1007/978-3-032-16723-1_7.
- [4] Shalileh S., Mirkin B. Community Partitioning over Feature-Rich Networks Using an Extended K-Means Method // *Entropy*. 2022. Vol. 24, No. 5. Art. 626. DOI: 10.3390/e24050626.
- [5] Biswas A., Biswas B. Defining quality metrics for graph clustering evaluation // *Expert Systems with Applications*. 2017. Vol. 71. P. 1–17. DOI: 10.1016/j.eswa.2016.11.011.
- [6] Howie J., Srinivasan V., Thomo A. Scaling Up Structural Clustering to Large Probabilistic Graphs Using Lyapunov Central Limit Theorem // *Proc. VLDB Endowment*. 2023. Vol. 16, No. 11. P. 3165–3177. DOI: 10.14778/3611479.3611516.
- [7] Rousseeuw P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis // *J. Comput. Appl. Math.* 1987. Vol. 20. P. 53–65. DOI: 10.1016/0377-0427(87)90125-7.
- [8] Caliński T., Harabasz J. A dendrite method for cluster analysis // *Communications in Statistics*. 1974. Vol. 3, No. 1. P. 1–27. DOI: 10.1080/03610927408827101.
- [9] Davies D. L., Bouldin D. W. A Cluster Separation Measure // *IEEE TPAMI*. 1979. Vol. PAMI-1, No. 2. P. 224–227. DOI: 10.1109/TPAMI.1979.4766909.
- [10] Halkidi M., Vazirgiannis M. Clustering validity assessment: finding the optimal partitioning of a data set // *Proc. IEEE ICDM 2001*. P. 187–194. DOI: 10.1109/ICDM.2001.989517.
- [11] Newman M. E. J., Girvan M. Finding and evaluating community structure in networks // *Physical Review E*. 2004. Vol. 69. 026113. DOI: 10.1103/PhysRevE.69.026113.
- [12] Mancoridis S., Mitchell B. S., Rorres C., Chen Y., Gansner E. R. Using automatic clustering to produce high-level system organizations of source code // *Proc. IWPC'98. IEEE*, 1998. P. 45–52. DOI: 10.1109/WPC.1998.693283.
- [13] Mitchell B. S., Mancoridis S. On the automatic modularization of software systems using the Bunch tool // *IEEE Trans. Software Engineering*. 2006. Vol. 32, No. 3. P. 193–208. DOI: 10.1109/TSE.2006.31.
- [14] Mirkin B. *Clustering: A Data Recovery Approach*. 2nd ed. Boca Raton: CRC Press, 2012.
- [15] Mirkin B. *Core Concepts in Data Analysis: Summarization, Correlation and Visualization*. London: Springer, 2011.

- [16] Aleskerov F., Chistyakov V.V., Kalyagin V. The threshold aggregation // Economics Letters. 2010. Vol. 107, No. 2. P. 261–262. DOI: 10.1016/j.econlet.2010.01.041.
- [17] Aleskerov F.T., Yakuba V.I., Yuzbashev D.A. A ‘threshold aggregation’ of three-graded rankings // Mathematical Social Sciences. 2007. Vol. 53. P. 106–110.
- [18] Ignatov D.I., Gnatyshak D.V., Kuznetsov S.O., Mirkin B.G. Triadic Formal Concept Analysis and triclustering: searching for optimal patterns // Machine Learning. 2015. Vol. 101, No. 1–3. P. 271–302. DOI: 10.1007/s10994-015-5487-y.
- [19] Ganter B., Wille R. Formal Concept Analysis: Mathematical Foundations. Berlin: Springer, 1999.
- [20] Mucha P.J., Richardson T., Macon K., Porter M.A., Onnela J.-P. Community Structure in Time-Dependent, Multiscale, and Multiplex Networks // Science. 2010. Vol. 328, No. 5980. P. 876–878. DOI: 10.1126/science.1184819.
- [21] Greene D., Doyle D., Cunningham P. Tracking the Evolution of Communities in Dynamic Social Networks // Proc. ASONAM 2010. IEEE. P. 176–183. DOI: 10.1109/ASONAM.2010.17.
- [22] Rossetti G., Cazabet R. Community Discovery in Dynamic Networks: A Survey // ACM Computing Surveys. 2018. Vol. 51, No. 2. Art. 35. DOI: 10.1145/3172867.
- [23] Shorrocks A.F. The Measurement of Mobility // Econometrica. 1978. Vol. 46, No. 5. P. 1013–1024. DOI: 10.2307/1911433.
- [24] Traag V.A., Waltman L., van Eck N.J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. 2019. Vol. 9. 5233. DOI: 10.1038/s41598-019-41695-z.
- [25] Zelnik-Manor L., Perona P. Self-tuning spectral clustering // NIPS 17. 2004.
- [26] Ledoit O., Wolf M. A well-conditioned estimator for large-dimensional covariance matrices // J. Multivariate Analysis. 2004. Vol. 88, No. 2. P. 365–411.
- [27] Wang B. et al. Similarity network fusion for aggregating data types on a genomic scale // Nature Methods. 2014. Vol. 11. P. 333–337.
- [28] Hennig C. Cluster-wise assessment of cluster stability // Computational Statistics & Data Analysis. 2007. Vol. 52, No. 1. P. 258–271.
- [29] Aitchison J. The Statistical Analysis of Compositional Data. Chapman & Hall, 1986.

А Абляция правил ребра

Полные таблицы по месяцам: `outputs/graphs/network_summary.csv`, `outputs/compare/ablation_layers.csv`, `outputs/compare/ablation_ari.csv`; сводки приведены в табл. 2–4 в п. 2.2. Temporal Leiden: `outputs/cluster/metrics_long_temporal_K*.csv`.

Б Свойства ICVI (доказательства)

Б.1. AVU при $K = 2$. Для кластера a единственный партнёр b : $\text{out}_a = \text{out}_b = S_{ab}$, знаменатель $\text{out}_a + \text{out}_b - S_{ab} = S_{ab}$, слагаемое в (9) равно 1. Два слагаемых, деление на $K = 2$: $\text{AVU} = 1$ при любом непустом разрезе (и 0 при пустом).

Б.2. AVU при $K = 3$. Пусть $W = S_{12} + S_{13} + S_{23}$ – полный вес разреза. Для пары (a, b) :

$$\text{out}_a + \text{out}_b - S_{ab} = (S_{ab} + S_{ac}) + (S_{ab} + S_{bc}) - S_{ab} = W. \quad (12)$$

Сумма по шести упорядоченным парам: $2W/W = 2$; делим на 3: $\text{AVU} = 2/3$ при любом разбиении с $W > 0$.

Б.3. Случайный уровень при $K \geq 4$. Для равных кластеров в однородном графе $S_{ab} \approx s$ для всех $a \neq b$: слагаемое $= s / ((K-1)s + (K-1)s - s) = 1/(2K-3)$, пар $K(K-1)$, деление на K :

$$AVU \approx \frac{K-1}{2K-3}, \quad (13)$$

то есть 0,60; 0,57; 0,56; 0,55 при $K = 4..7$, предел $1/2$. Аналогично $AVI \approx 1/K$: доля внутренних рёбер у случайного кластера размера N/K равна $1/K$.

Б.4. AVU видит только форму разреза. Умножение всех внутренних весов на константу не меняет ни одного S_{ab} , $a \neq b$, а значит и AVU. Разбиения с 99 % рёбер внутри и с 10 % внутри получают одинаковый AVU при одинаковом разрезе, поэтому AVU нельзя читать в отрыве от AVI (тест `test_avu_sees_only_cut_shape`).

Б.5. TurboMQ $\equiv K \cdot AVI$. TurboMQ $= \sum_a \mu_a / (\mu_a + \frac{1}{2} \sum_{b \neq a} (\varepsilon_{ab} + \varepsilon_{ba}))$ определён для ор-графа; неориентированное ребро соответствует паре встречных дуг: $\mu_a = S_{aa}$, $\varepsilon_{ab} = \varepsilon_{ba} = S_{ab}$, откуда слагаемое $= S_{aa} / (S_{aa} + out_a)$, изолируемость кластера a . Сумма по кластерам $= K \cdot AVI$, см. (8).

Б.6. Кластер без рёбер. В формуле Pattern строка с нулевой суммой даёт изолируемость 0, то есть «идеально изолированный» кластер из изолятов штрафует; наш граф связный без изолятов (MST), поэтому случай не возникает.

В Конфигурации и время прогона

Таблица 13. Шаги конвейера, конфигурации и время прогона (MacBook M-серии, 1 ядро, если не указано).

Шаг	Команда	Конфиг	Время
Данные	<code>make data</code>	<code>configs/data.yaml</code>	1–2 мин (скачивание ≈ 600 МБ)
Признаки	<code>make features</code>	<code>configs/features.yaml</code>	3 с
Графы (3 слоя + SNF, 24 мес.)	<code>make graphs</code>	<code>configs/graph.yaml</code>	≈ 2 мин
Кластеризация 5 методов $\times 7 K \times 24$ мес.	<code>make cluster</code>	<code>configs/methods.yaml</code>	k-means 14 с, Ward 6 с, Spectral 57 с, Leiden 706 с, KEFRiN 148 с, KEFRiN сбал. 130 с
temporal Leiden ($K \in \{4, 6, 8\}$)	<code>make cluster</code>	<code>configs/methods.yaml</code>	≈ 8 –9 мин на K
Сравнение (нулевые модели, бутстрэп, абляция)	<code>make compare</code>	<code>configs/compare.yaml</code>	≈ 45 мин
Динамика (с бутстрэпом уверенности)	<code>make dynamics</code>	<code>configs/dynamics.yaml</code> , <code>final.yaml</code>	≈ 3 мин (все ядра)
Интерпретация	<code>make interpret</code>	<code>configs/interpret.yaml</code> , <code>type_names.json</code>	5 с
Данные лендинга, рисунки	<code>make site</code>	–	30 с

Версии пакетов зафиксированы в `requirements.txt` (Python 3.12); `seed = 42` во всех стохастических шагах; тесты запускаются через `make test` (106 тестов, включая численную сверку

ICVI с Pattern при PATTERN_DIR). Полный прогон `make all` без temporal Leiden занимает около часа.